MODEL LIFECYCLE



CRIANDO MODELOS SIMPLES DE MACHINE LEARNING II

DIEGO RODRIGUES DSC

INFNET

MODEL LIFECYCLE: CRIANDO MODELOS SIMPLES DE MACHINE LEARNING II

PARTE 1 : TEORIA

- DATA PREPARATION
 - AUMENTO DE DADOS
 - NORMALIZAÇÃO
- MODELING
 - BIAS VS VARIANCE
- EVALUATION
 - VALIDAÇÃO CRUZADA
 - PONTO DE OPERAÇÃO
 - MATRIZ DE CONFUSÃO

PARTE 2 : PRÁTICA

NOTEBOOK CLASSIFICAÇÃO
 IRIS KNN KFOLDS



Produzir Ação

CICLO DE VIDA DO MODELO

Baseado em Dados

AMBIENTE PYTHON

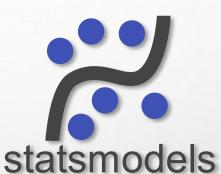


4. Variáveis Aleatórias



5. Visualização

6. Estimação e Inferência



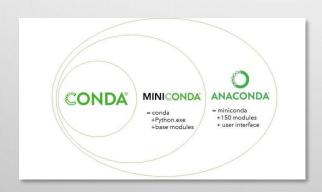


7. Machine Learning





1. Editor de Código



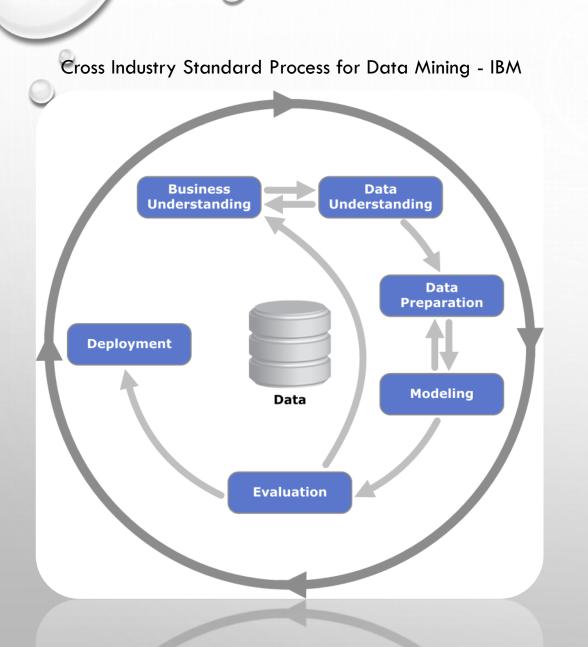
2. Gestor de Ambiente



3. Ambiente Python do Projeto



3. Notebook Dinâmico



1) Requerimentos e Análise de Negócio

Entendimento do problema decisório, dados relacionados & revisão bibliográfica.

2) Preparação dos Dados

Entendimento das fontes de dados, dos tipos e elaboração da representação.

3) Modelagem

Análise Exploratória, Seleção de atributos e treinamento.

4) Avaliação

Seleção do melhor modelo.

5) Liberação

Liberação do modelo no ambiente de produção.



DATA PREPARATION

AUMENTO DE DADOS

Aumento de Dados (Data Augmentation) é uma técnica poderosa utilizada para aumentar a quantidade e diversidade do conjunto de dados de treinamento, sem a necessidade de coletar novos dados.

Ela é aplicada em vários domínios, como imagens, texto e áudio, e envolve a criação de novas observações a partir de re-amostragem ou transformações nos dados existentes.

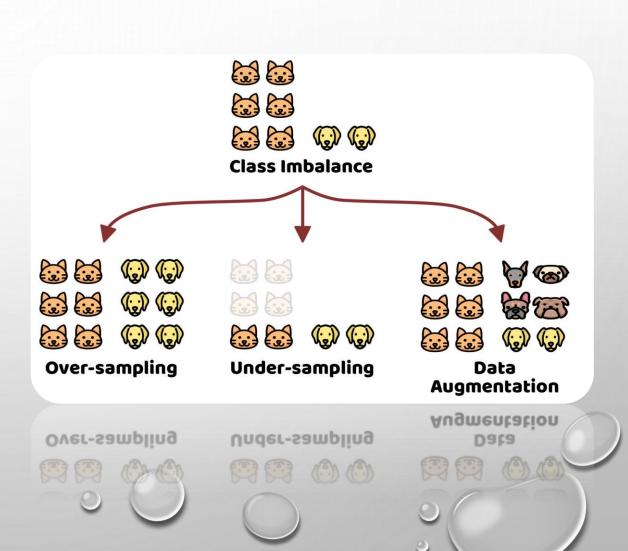


AUMENTO DE DADOS: BALANCEAMENTO DE CLASSES

Aumento de Dados pode ser utilizado para diferentes estratégias de balanceamento das classes!

BENEFÍCIOS ADICIONAIS

- Robustez a Ruído: Aumentar a capacidade do modelo de lidar com dados ruidosos ou imperfeitos, introduzindo variações que o ajudam a generalizar melhor.
- Melhoria da Generalização: Evitar o overfitting ao modelo de treinamento, fornecendo exemplos diversificados que permitem ao modelo aprender características mais robustas.



AUMENTO DE DADOS: TIPOS DE TRANSFORMAÇÕES

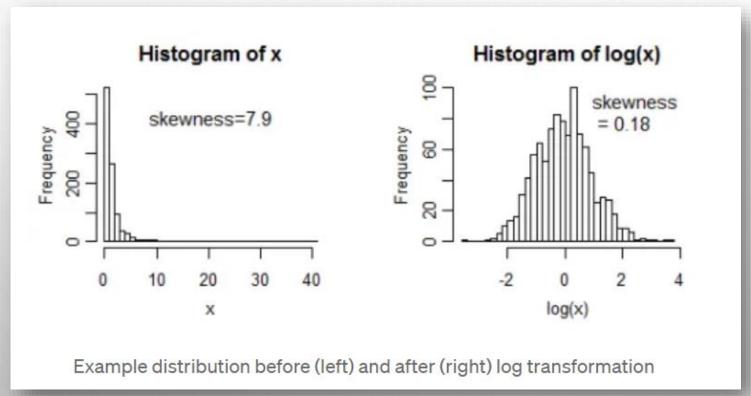
- •Transformações Geométricas: Como rotações, translações, e alterações de escala, aplicadas a diferentes tipos de dados.
- •Alterações em Valores: Como mudança na intensidade de pixels em imagens, adição de ruído ou substituição de palavras em textos.
- •Composição e Mistura: Combinação de diferentes amostras de dados para criar novos exemplos compostos.

Geometric Augmentations Translation in x-axis Translation in y-axis Translation in y-axis Random Shear in x-axis Random Shear in y-axis Random Rotation Scaling in x-axis Scaling in y-axis Reflection in x-axis [0.85 0.15] [0.85 0.15]



NORMALIZAÇÃO

NORMALIZAÇÃO



Transformar as variáveis originais por funções, facilitando o problema numérico de otimização e ao mesmo tempo inserindo "não-linearidades" para resolver um problema não-linear de forma linear.

https://medium.com/@isalindgren313/transformations-scaling-and-normalization-420b2be12300

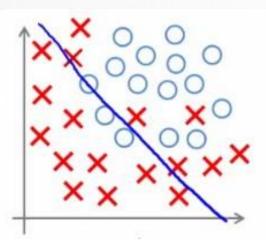
NORMALIZAÇÃO

TRANSFORMATION	USE IF	LIMITATIONS	SPSS EXAMPLES
Square/Cube Root	Variable shows positive skewness Residuals show positive heteroscedasticity Variable contains frequency counts	Square root only applies to positive values	compute newvar = sqrt(oldvar). compute newvar = oldvar**(1/3).
Logarithmic	Distribution is positively skewed	Ln and log10 only apply to positive values	compute newvar = In(oldvar). compute newvar = Ig10(oldvar).
Power	Distribution is negatively skewed	(None)	compute newvar = oldvar**3.
Inverse	Variable has platykurtic distribution	Can't handle zeroes	compute newvar = 1 / oldvar.
Hyperbolic Arcsine	Distribution is positively skewed	(None)	compute newvar = In(oldvar + sqrt(oldvar**2 + 1)).
Arcsine	Variable contains proportions	Can't handle absolute values > 1	compute newvar = arsin(oldvar).
Arcsine	Variable contains proportions	Can't handle absolute values > 1	compute newvar = arsin(oldvar).
	Distribution is positively skewed	(None)	compute newvar = In(oldvar + sqrt(oldvar**2 + 1)).



MODELING

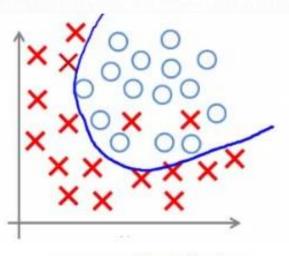
CAPACIDADE E GENERALIZAÇÃO



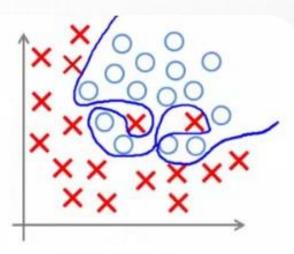
Under-fitting

(too simple to explain the variance)

explain the variance)



Appropriate-fitting

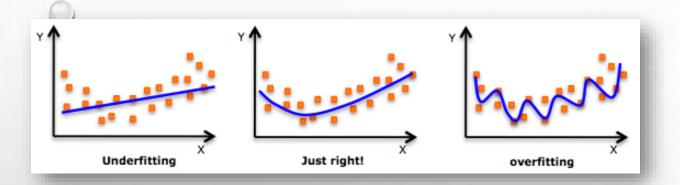


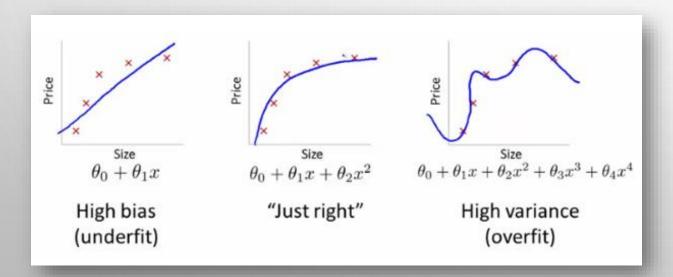
Over-fitting

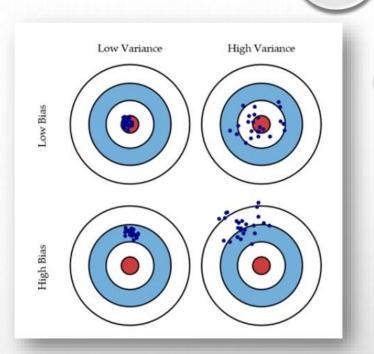
(forcefitting -- too good to be true)

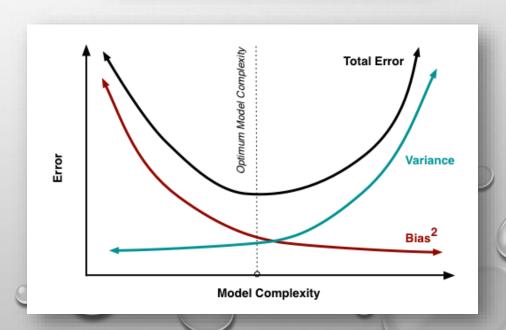


BIAS x VARIANCE









REGULARIZAÇÃO

In mathematics, statistics, finance,^[1] and computer science, particularly in machine learning and inverse problems, **regularization** is a process that changes the result answer to be "simpler". It is often used to obtain results for ill-posed problems or to prevent overfitting.^[2]

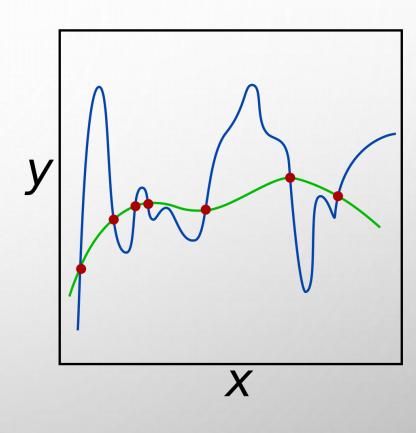
Although regularization procedures can be divided in many ways, the following delineation is particularly helpful:

- Explicit regularization is regularization whenever one explicitly adds a term to the optimization
 problem. These terms could be priors, penalties, or constraints. Explicit regularization is commonly
 employed with ill-posed optimization problems. The regularization term, or penalty, imposes a cost on
 the optimization function to make the optimal solution unique.
- Implicit regularization is all other forms of regularization. This includes, for example, early stopping, using a robust loss function, and discarding outliers. Implicit regularization is essentially ubiquitous in modern machine learning approaches, including stochastic gradient descent for training deep neural networks, and ensemble methods (such as random forests and gradient boosted trees).

In explicit regularization, independent of the problem or model, there is always a data term, that corresponds to a likelihood of the measurement and a regularization term that corresponds to a prior. By combining both using Bayesian statistics, one can compute a posterior, that includes both information sources and therefore stabilizes the estimation process. By trading off both objectives, one chooses to be more addictive to the data or to enforce generalization (to prevent overfitting). There is a whole research branch dealing with all possible regularizations. In practice, one usually tries a specific regularization and then figures out the probability density that corresponds to that regularization to justify the choice. It can also be physically motivated by common sense or intuition.

In machine learning, the data term corresponds to the training data and the regularization is either the choice of the model or modifications to the algorithm. It is always intended to reduce the generalization error, i.e. the error score with the trained model on the evaluation set and not the training data.^[3]

One of the earliest uses of regularization is Tikhonov regularization (ridge regression), related to the method of least squares.





EVALUATION



GENERALIZAÇÃO: IDENTIFICANDO OS HIPERPARÂMETROS ÓTIMOS

LEAVE ONE OUT

 Uma única observação é deixada de fora a cada treinamento. N treinamentos são realizados para calcular a estatística de erro.

K FOLDS

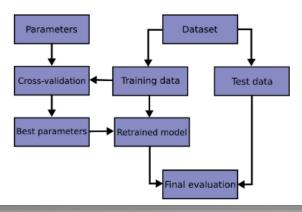
 Amostra é dividida em K conjuntos. K treinamentos são realizados, mantendo um conjunto como fora-da-amostra.

BOOTSTRAPPING

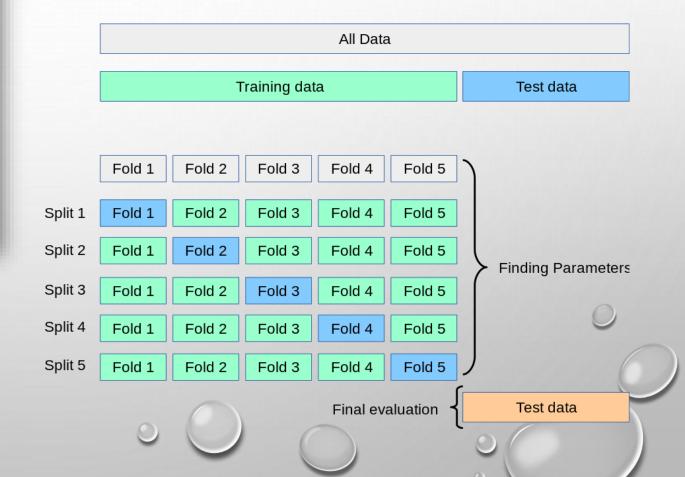
 O algoritmo itera, amostrando aleatoriamente M observação quantidade Q desejada de treinamentos.

3.1. Cross-validation: evaluating estimator performance

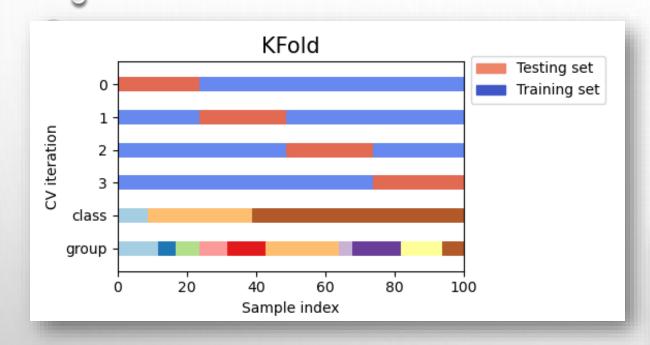
Learning the parameters of a prediction function and testing it on the same data is a methodological mistake: a model that would just repeat the labels of the samples that it has just seen would have a perfect score but would fail to predict anything useful on yet-unseen data. This situation is called **overfitting**. To avoid it, it is common practice when performing a (supervised) machine learning experiment to hold out part of the available data as a **test set** x_test, y_test. Note that the word "experiment" is not intended to denote academic use only, because even in commercial settings machine learning usually starts out experimentally. Here is a flowchart of typical cross validation workflow in model training. The best parameters can be determined by grid search techniques.

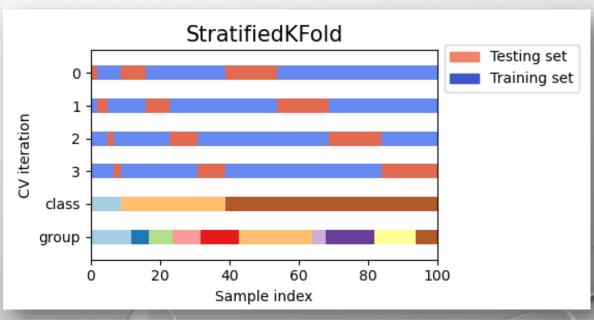


VALIDAÇÃO CRUZADA



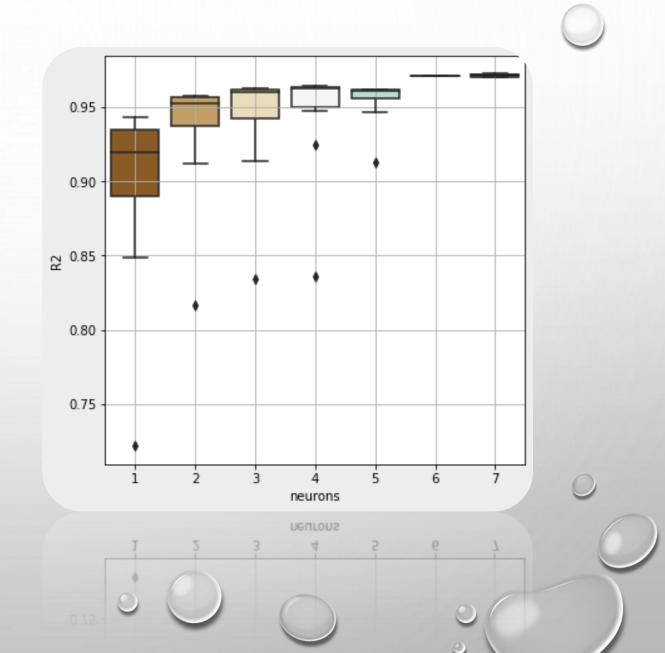
K-FOLDS & K-FOLDS ESTRATIFICADO







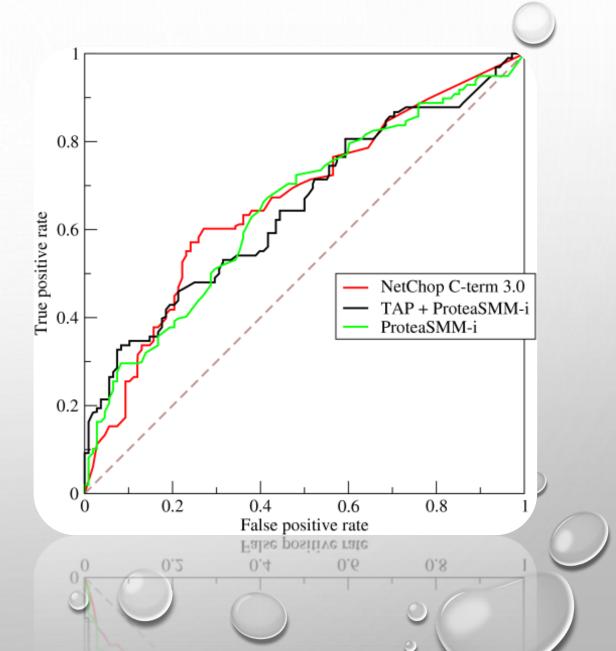
- Iteração dos hiperparâmetros
- Seleção da Figura de Mérito
- Seleção da Estatística de Ganho



PONTO DE OPERAÇÃO

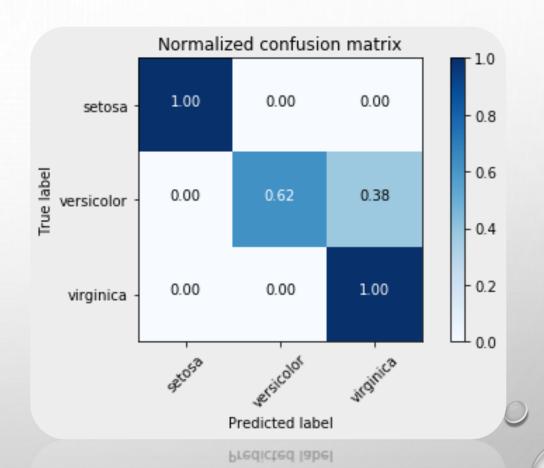
Curva ROC

Calibra a saída do modelo,
 ajudando a configurar o ponto de operação entre Precisão / Recall / Acurácia.

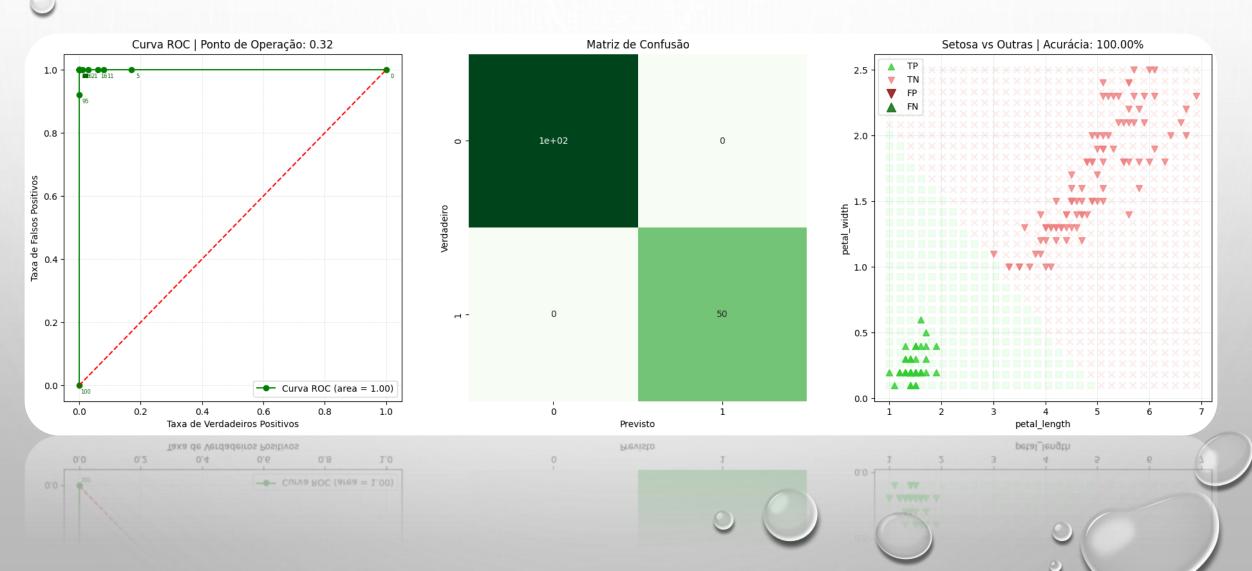


MATRIZ DE CONFUSÃO

Comparação entre o resultado do classificador para as diferentes classes.



PONTO DE OPERAÇÃO





CRIANDO MODELOS SIMPLES DE MACHINE LEARNING III